Semana 2 – Normalización de salarios y valores faltantes

```
# ========================================
# MINERÍA DE DATOS - CLASE 2
# Limpieza, Transformación y EDA
# Autor: Lionel Martinez, con asistencia de IA
# ========================================

# ============================
# 1. IMPORTAR LIBRERÍAS
# ============================
import pandas as pd
import numpy as np
from sklearn.preprocessing import MinMaxScaler, OrdinalEncoder
import matplotlib.pyplot as plt

# ============================
# 2. CREAR DATASET
# ============================
df = pd.DataFrame({
    "ID": [1, 2, 3, 4, 5],
    "Nombre": ["Juan", "María", "Pedro", "Ana", "Luis"],
    "Edad": [32, -28, 40, 35, 50],
    "Nivel_Educativo": ["Licenciado", "Ingeniero", "Doctorado", "Licenciado", "Doctorado"],
    "Salario": [50000, 60000, None, 55000, 200000],
    "Categoria": ["Junior", "Senior", "Senior", "Junior", "Manager"],
    "Estado": ["Activo", "ACTIVO", "Inactivo", "Activo", "Inactivo"]
})

print("\nDATASET ORIGINAL:\n")
print(df)

# ============================
# 3. TIPOS DE DATOS
# ============================
print("\nTIPOS DE DATOS:\n")
print(df.dtypes)

# ============================
# 4. LIMPIEZA DE DATOS
# ============================

# 4.1 Corregir edad negativa
df["Edad"] = df["Edad"].abs()

# 4.2 Valores faltantes (Salario)
df["Salario"].fillna(df["Salario"].median(), inplace=True)
```

```
# 4.3 Normalizar texto (Estado)
df["Estado"] = df["Estado"].str.capitalize()

# 4.4 Detectar outliers con IQR
Q1 = df["Salario"].quantile(0.25)
Q3 = df["Salario"].quantile(0.75)
IQR = Q3 - Q1

limite_inferior = Q1 - 1.5 * IQR
limite_superior = Q3 + 1.5 * IQR

# Filtrar outliers
df = df[(df["Salario"] >= limite_inferior) & (df["Salario"] <= limite_superior)]

print("\nDATASET LIMPIO:\n")
print(df)

# ============================
# 5. TRANSFORMACIÓN DE DATOS
# ============================

# 5.1 Codificación ordinal (Nivel Educativo)
orden = [["Licenciado", "Ingeniero", "Doctorado"]]
encoder = OrdinalEncoder(categories=orden)
df["Nivel_Cod"] = encoder.fit_transform(df[["Nivel_Educativo"]])

# 5.2 Normalización de salario
scaler = MinMaxScaler()
df["Salario_Normalizado"] = scaler.fit_transform(df[["Salario"]])

# 5.3 Nueva variable
df["Años_Hasta_Jubilacion"] = 65 - df["Edad"]

print("\nDATASET TRANSFORMADO:\n")
print(df)

# ============================
# 6. ANÁLISIS EXPLORATORIO (EDA)
# ============================

print("\nESTADÍSTICAS DESCRIPTIVAS:\n")
print(df.describe())

# ============================
# 7. VISUALIZACIONES
# ============================

# 7.1 Histograma de salarios
```

```
plt.figure()
plt.hist(df["Salario"])
plt.title("Distribución de Salarios")
plt.xlabel("Salario")
plt.ylabel("Frecuencia")
plt.show()

# 7.2 Relación Edad vs Salario
plt.figure()
plt.scatter(df["Edad"], df["Salario"])
plt.title("Edad vs Salario")
plt.xlabel("Edad")
plt.ylabel("Salario")
plt.show()

# ============================
# 8. USO DE LLM (EJEMPLO)
# ============================

# Prompt utilizado:
# "¿Cómo detectar y eliminar outliers en Python?"

# Síntesis:
# Los outliers pueden detectarse usando el método IQR o Z-score.
# En este trabajo se utilizó IQR por ser simple y efectivo.
# Luego se eliminaron los valores fuera del rango permitido.

print("\nPROCESO FINALIZADO CORRECTAMENTE")
```

✓ Tipos de datos → se muestran con `df.dtypes`
✓ Limpieza:

- Edad negativa corregida
- Salario faltante imputado con mediana
- Estado normalizado (Activo / Inactivo)
- Outliers eliminados con IQR

✓ Transformación:

- Codificación ordinal (Nivel educativo)
- Normalización de salario
- Nueva variable: **Años hasta jubilación**

✓ EDA:

- Estadísticas descriptivas
- 2 gráficos:

    - Histograma (salarios)
    - Scatter (edad vs salario)

✓ Uso de LLM:

- Prompt incluido
- Síntesis explicada

Explicación (Markdown)

Tipos de datos:

- Edad: numérico
- Salario: numérico
- Nivel educativo: categórico ordinal
- Categoría: categórico
- Estado: categórico

Interpretación EDA:

- Se observa que los salarios están concentrados en valores medios
- Existe relación positiva entre edad y salario (a mayor edad, mayor salario en general)

- Conclusión final tipo:

  “El preprocesamiento permitió mejorar la calidad de los datos, eliminando errores e inconsistencias, lo cual es fundamental para obtener modelos confiables en minería de datos.”